
Análisis y Reconocimiento de Patrones de Señales Biomédicas Relacionadas a las Etapas de Sueño

Oscar Rodrigo López Portillo



UNIVERSIDAD DEL VALLE DE GUATEMALA
Facultad de Ingeniería



**Análisis y Reconocimiento de Patrones de Señales Biomédicas
Relacionadas a las Etapas de Sueño**

Trabajo de graduación presentado por Oscar Rodrigo López Portillo
para optar al grado académico de Licenciado en Ingeniería Mecatrónica

Guatemala,

2020

Vo.Bo.:

(f) _____
Dr. Luis Alberto Rivera Estrada

Tribunal Examinador:

(f) _____
Dr. Luis Alberto Rivera Estrada

(f) _____

(f) _____

Fecha de aprobación: Guatemala, de de 2020.

Durante muchos años, Guatemala ha sufrido de diversos problemas socio – económicos, desempleo, pobreza, un débil e insuficiente sistema de salud, la falta de educación, pero también problemas como la corrupción, la inseguridad, que han provocado que el país no tenga un buen desarrollo y crecimiento en distintas disciplinas.

Viendo el lado positivo de la situación, esto ha generado que día a día los guatemaltecos vivamos una constante lucha por sobrevivir en la búsqueda de tener una mejor calidad de vida. Tratando salir adelante en pro de mejores oportunidades, en los últimos años se han desarrollado distintos proyectos que demuestran que se tiene mucho potencial en la población, que pueden aprovecharse para desarrollar tecnologías que apoyen a mejorar la calidad de vida, así como generar estrategias que ayuden a reducir o solucionar en parte los diferentes conflictos que se han vivido en el país.

Uno de los campos que ha demostrado tener un gran potencial para los guatemaltecos en el transcurso de los años es el campo deportivo, en donde se han obtenido grandes logros y reconocimientos a nivel internacional en distintas ramas. Debido a esto, se ha buscado mejorar el rendimiento de los atletas para que puedan seguir mejorando y cumpliendo sus metas, motivando con ello, que cada vez más personas quieran ser parte de los distintos deportes que se practican.

Basado en esto, nace la idea del presente proyecto de investigación que busca dar las bases para que pueda desarrollarse una herramienta capaz de analizar el sueño de los atletas y mejorar su proceso de recuperación y descanso, logrando con ello, que puedan dar su máximo potencial y lograr elevar sus rendimientos.

Esta fase del proyecto consiste en la elaboración de distintos clasificadores que reciban las señales biomédicas por medio del uso de distintos electrodos en distintas posiciones, siguiendo estándares médicos para la correcta medición de estas señales y así poder procesarlas e ir reconociendo las diferentes etapas del sueño en tiempo real. Esto sería uno de los puntos de partida para futuras fases de este proyecto en donde se integre la generación de los pulsos binaurales y la clasificación de etapas para la estimulación de cada una y así poder experimentar los diferentes efectos que estos tengan durante el transcurso de la noche.

Para algunos de nosotros, además de distintos privilegios en nuestro día a día, se suma que hemos tenido el privilegio de poder seguir una carrera universitaria, es importante que demos el máximo desempeño para poder crecer no solo como personas y profesionales, sino que también aportar a la sociedad en la que hemos crecido y pueda mejorarse de forma colectiva con el fin de multiplicar las oportunidades para las diferentes generaciones.

Para la realización de este proyecto es de gran importancia agradecer primeramente a mi familia y amigos, quienes han estado apoyándome durante estos años de carrera universitaria, a la Universidad del Valle de Guatemala por brindarme durante estos años una gran variedad de conocimientos, experiencias y herramientas que me han sido útiles para poder llegar hasta donde estoy ahora y poder seguir creciendo de manera profesional. A mi asesor personal el Dr. Luis Alberto Rivera, por su increíble dedicación, compromiso y motivación que me ha proporcionado durante todo este proceso y que me han sido útiles para poder realizar un proyecto que proporcione resultados importantes para la Universidad del Valle. Por último, y por ello, no menos importante, al Dr. Jorge Donis, por su apoyo en compartir sus conocimientos en el área de Neurofisiología y Psicología Clínica que ha sido de gran importancia para lograr los objetivos planteados.

| | |
|---|-------------|
| Prefacio | IV |
| Lista de figuras | VIII |
| Lista de cuadros | IX |
| Resumen | X |
| Abstract | XI |
| 1. Introducción | 1 |
| 2. Antecedentes | 3 |
| 3. Justificación | 5 |
| 4. Objetivos | 7 |
| 5. Alcance | 8 |
| 6. Marco teórico | 9 |
| 6.1. Ondas cerebrales | 9 |
| 6.1.1. Ondas Delta 0.5Hz a 4 Hz | 9 |
| 6.1.2. Ondas Theta 4 Hz a 7 Hz | 10 |
| 6.1.3. Ondas Alfa 7 Hz a 12 Hz | 10 |
| 6.1.4. Ondas Beta 13 Hz a 39 Hz | 10 |
| 6.1.5. Ondas Gamma 39Hz en adelante | 10 |
| 6.2. Señales binaurales | 11 |
| 6.3. El ciclo del sueño | 13 |
| 6.4. Electro - Cap | 14 |
| 6.5. Sistema Internacional 10-20 | 15 |
| 6.6. OpenBCI | 17 |
| 6.7. Cyton Board y Dongle | 18 |
| 6.8. Machine Learning | 20 |

| | |
|---|-----------|
| 6.8.1. Red Neuronal Artificial | 21 |
| 6.8.2. Aprendizaje Supervisado | 22 |
| 6.8.3. Aprendizaje no supervisado | 24 |
| 7. Obtención de señales EEG | 25 |
| 7.1. Familiarización con la Cyton Board y el Eletro - cap | 25 |
| 7.2. Conexión Matlab – Cyton Board | 26 |
| 7.2.1. Indicadores para la clasificación de señales | 31 |
| 8. Clasificación de señales | 34 |
| 8.1. señales de prueba | 34 |
| 8.2. señales en tiempo real | 35 |
| 9. Almacenamiento de las señales | 36 |
| 9.1. Búsqueda de alternativas | 36 |
| 9.1.1. FireBase | 36 |
| 9.1.2. MySQL. | 37 |
| 9.2. Desarrollo de la base de datos. | 38 |
| 10.Pruebas y Resultados | 40 |
| 10.1. Pruebas offline | 40 |
| 10.1.1. Primeras pruebas | 41 |
| 10.1.2. Pruebas posteriores | 43 |
| 11.Conclusiones | 45 |
| 12.Recomendaciones | 46 |
| 13.Bibliografía | 47 |
| 14.Anexos | 49 |
| 14.1. Planos de construcción | 49 |
| 15.Glosario | 50 |

Lista de figuras

| | | |
|-----|--|----|
| 1. | Ondas Cerebrales[5] | 11 |
| 2. | categorías principales de estados de ondas cerebrales utilizadas en la música binaural beats y sus beneficios asociados [5] | 12 |
| 3. | Hipnograma estandar del sueño | 13 |
| 4. | Electro Cap y sus componentes[12] | 15 |
| 5. | Ubicación de electrodos según el Sistema Internacional 10-20[13] | 17 |
| 6. | Interfaz grafica de OpenBCI [14] | 18 |
| 7. | Cyton Boarde de OpenBCI [15] | 19 |
| 8. | Dongle de OpenBCI [15] | 20 |
| 9. | Modelo de la neurona artificial [17] | 21 |
| 10. | Modelo de la neurona artificial [18] | 22 |
| 11. | Principales modelos de RNAs con aprendizaje supervisado [18] | 23 |
| 12. | Captura de gestos para la verificación de funcionamiento | 26 |
| 13. | Captura de gestos del canal 1 y 2 utilizando el programa desarrollado. | 27 |
| 14. | Captura de gestos del canal 3 y 4 utilizando el programa desarrollado. | 28 |
| 15. | Captura de gestos del canal 5 y 6 utilizando el programa desarrollado. | 29 |
| 16. | Captura de gestos del canal 7 y 8 utilizando el programa desarrollado. | 30 |
| 17. | Captura de gestos de los 8 canales utilizando OpenBCI_GUI. | 31 |
| 18. | Ondas Gamma obtenidas con el programa en Matlab. | 32 |
| 19. | Ondas Beta obtenidas con el programa en Matlab. | 32 |
| 20. | Ondas Delta obtenidas con el programa en Matlab. | 32 |
| 21. | Vista de la pagina de donde se obtuvieron los datos. | 34 |
| 22. | Archivos de datos disponibles. | 35 |
| 23. | Pagina de inicio de FireBase. | 37 |
| 24. | Vista del almacenamiento de gestos pt1. | 38 |
| 25. | Vista del almacenamiento de gestos pt2. | 38 |
| 26. | Matrices de confución para la red neuronal con un canal de datos. | 41 |
| 27. | Matrices de confusión para la maquina de vectores de soporte con kernel Lineal con un canal de datos. | 42 |
| 28. | Matrices de confusión para k- nearest neighbor con un canal de datos. | 42 |

| | | |
|-----|---|----|
| 29. | Matrices de confusión para la red neuronal. | 43 |
| 30. | Matrices de confusión para la maquina de vectores de soporte con kernel Lineal. | 44 |
| 31. | Matrices de confusión para k- nearest neighbor. | 44 |

Lista de cuadros

| | | |
|----|--------------------------------|----|
| 1. | Pruebas preliminares | 16 |
|----|--------------------------------|----|

Este proyecto consistió en la realización de la segunda fase de un sistema de clasificación automática de las etapas del sueño, capaz de generar pulsos binaurales para combatir trastornos del sueño en los atletas. En esta segunda fase se realizó un algoritmo capaz de poder obtener los datos provenientes de la conexión entre el electro - cap y la Cyton Board, para luego procesar los datos y poderlos utilizar en distintos clasificadores, los cuales están basados en los principios de *Machine learning*. Para poder aplicar esto primero se analizaron diferentes características que sirvieran para poder extraer la mayor información posible a las señales y así los clasificadores pudieran identificar los distintos patrones correspondientes a cada una de las etapas del sueño. Para el entrenamiento de los clasificadores se utilizaron datos de distintas polisomnografías utilizando las características previamente analizadas las cuales fueron: Zero Crossing (ZC), Mean Absolute Value (MAV), Max Min Distance (MMD), Slow wave activity (SWA) y Kurtosis. Todos los resultados obtenidos y sus señales finalmente fueron almacenados en una base de datos que se realizó en conjunto con los clasificadores y así poder tener un conjunto de datos biomédicos según estándares internacionales.

Abstract

CAPÍTULO 1

Introducción

En los últimos años el desarrollo en el campo científico y tecnológico ha sido bastante grande y se han desarrollado distintas tecnologías que mejoran la calidad de vida de las personas. A pesar de todos estos avances, aún hay varios campos que no se han explorado con mas profundidad. Este es el caso del análisis del sueño en diferentes aplicaciones, tanto para la vida cotidiana como para la profesional y la deportiva. Este es un campo que tiene un gran peso debido a que dormir es una de las actividades esenciales para el desarrollo de cualquier ser humano. Al dormir, una persona se recupera tanto física como psicológicamente.

Teniendo noción de lo anterior se busca enfocar esta área al ámbito deportivo en donde el proceso de recuperación y descanso del atleta es un factor importante que afecta en su rendimiento. Debido a que el agotamiento provocado por la exigencia y presión del día a día en estos deportistas, ocasiona una mayor susceptibilidad a padecer trastornos del sueño con el paso de los años.

Dado que un atleta profesional debe de optimizar al máximo sus horas de sueño para tener el mejor rendimiento y recuperación posible. Con este trabajo se busca crear el diseño de un sistema capaz de monitorear la actividad cerebral de un atleta mientras duerme y poder identificar en qué etapas de sueño se encuentra y así poder tener un control del proceso de recuperación y descanso para poder aplicar diferentes medidas para mejorar la recuperación del atleta.

Este documento tiene como objetivo mostrar resultados que sirvan como base para futuras investigaciones dentro de esta rama de investigación, también se espera que sirva para el desarrollo de distintas fases del proyecto que ayuden a mejorar este proceso de identificación y aplicación de las etapas del sueño. También se espera que este documento ayude a contribuir a la comunidad científica en temas como el comportamiento de las ondas cerebrales y sus diferentes técnicas de análisis, el uso de *machine learning* para el análisis de estas señales y poder reconocer las diferentes etapas del sueño en tiempo real. Cabe mencionar que este proyecto se realizó como continuación de una fase anterior.

El objetivo principal de este documento es poder implementar diferentes técnicas de reconocimiento de patrones para poder analizar señales biomédicas y así poder monitorear las distintas etapas de sueño en tiempo real. Para esto se plantaron distintas metas para poder llevar a cabo el proyecto, dichas metas consisten en poder obtener una colección de señales biomédicas que cumplan con los distintos estándares internacionales y poder utilizar dichas señales en futuros análisis, ya sea para alguna continuación de este proyecto o de algún otro que surja en el futuro. También se busca aplicar distintas técnicas de selección de características para el reconocimiento de patrones y poder analizar cuales tienen un mejor resultado en la clasificación de las señales biomédicas y por último se busca poder realizar e implementar una herramienta de hardware y software que permita analizar y reconocer las distintas etapas del sueño. Ya teniendo en cuenta los objetivos que se desean alcanzar se organizó de manera que se explicara el proceso en que se realizó todo desde la obtención de las señales, su clasificación y almacenamiento, seguido de una sección en donde se muestran los resultados más significativos del proyecto.

Se espera que con esta investigación toda persona interesada en el tema, pueda comprender los diferentes procesos que se realizaron para que puedan replicarlos, también se espera que con el tiempo más estudiantes de la Universidad Del Valle de Guatemala se interesen en el tema y decidan continuar con este proyecto y así lograr mejores resultados y poder expandir el alcance de este estudio.

El estudio de señales del cuerpo humano ha sido de gran importancia durante los años debido a que se busca tener un mejor entendimiento del cuerpo y de cómo mejorar algunos factores negativos tales como detección de atrofas musculares, trastornos del sueño, problemas de epilepsia y varios mas. Esto ha generado que el estudio y análisis de señales biomédicas haya tenido un gran crecimiento a lo largo de los años.

En la Universidad del Valle de Guatemala se han desarrollado varios proyectos relacionados a estas señales generadas por el cuerpo. En 2018 se realizaron dos proyectos, uno buscaba mejorar el rendimiento de los atletas en base al análisis y desarrollo de un sistema de entrenamiento [1] y el otro que buscaba utilizar el *Neurofeedback* para mejorar el rendimiento en atletas [2]. Ambos proyectos requirieron de la utilización de los sistemas de OpenBCI para realizar lecturas cerebrales. En ambos estudios era necesario realizar lecturas mientras que una persona realizaba determinadas tareas y en base a las diferentes lecturas se generaban distintos estímulos ya fueran positivos o negativos.

El objetivo principal de este proyecto era entrenar el cerebro del sujeto de prueba para controlar ciertos procesos neuronales, por medio de estos estímulos aplicados a los pacientes en base a las técnicas de *neurofeedback*. Esto con el fin de potenciar la capacidad del sujeto para manejar situaciones de estrés, o bien, situaciones en las que necesitase prestar un mayor enfoque en la tarea a realizar.

Otro de los proyectos que se han trabajado en la universidad trata acerca de la generación de Pulsos binaurales a través de un sistema de monitoreo de señales electroencefalográficas (EEG). Este proyecto fue planteado como una primera fase, en donde se buscaba generar pulsos binaurales mediante la lectura y clasificación de las etapas del sueño de manera automática utilizando conocimientos de *machine learning*. En ese proyecto se lograron varios resultados positivos respecto a la clasificación de las señales y generación de audios para estimular las ondas binaurales por lo que surgió el interés de continuar con este proyecto y poder obtener mejores resultados.

La clasificación de las etapas del sueño en base a las señales bioeléctricas ha sido ampliamente investigado y en donde se han presentado resultados prometedores, lo cual ayuda

a pensar que la clasificación de estas señales a través de una computadora independiente es algo alcanzable. En el libro *Sleep Stage Classification Using EEG Signal Analysis: A Comprehensive Survey and New Investigation* [3] se hace una recopilación de características que se han utilizado en este tipo de estudio además de distintos clasificadores que se han utilizado para el reconocimiento de los distintos patrones del sueño.

A lo largo de su vida una persona duerme aproximadamente una tercera parte de ella. Esto provoca que el estudio del sueño tenga una gran importancia, pero lamentablemente no se han realizado tantas investigaciones en esta área. Dormir es un proceso de gran importancia debido a que es la manera en la que el cuerpo humano se desarrolla y restaura. Esto tiene un mayor impacto en los atletas ya que ellos requieren de un buen descanso para poder tener un buen rendimiento en sus respectivas disciplinas. En base a diferentes estudios se ha demostrado que gran parte de los atletas poseen desórdenes de conciliación y mantenimiento del sueño. En otras palabras, estos atletas poseen un sueño menos eficiente al del resto de las personas lo cual puede tener repercusiones en su salud.

Los estudios del sueño pueden ayudar al médico a diagnosticar trastornos respiratorios relacionados con el sueño, como la apnea del sueño, trastornos convulsivos relacionados con el sueño, trastornos del movimiento relacionados con el sueño y trastornos del sueño que causan cansancio extremo durante el día como la narcolepsia. Los médicos, también, pueden usar los estudios del sueño para ayudar a diagnosticar o descartar el síndrome de las piernas inquietas.

Según un estudio realizado por la Universidad de Finlandia Oriental y la Clínica de Sueño Oivauni, un 22 % de los atletas estudiados reportaron tener problemas para dormir mientras se encontraban fuera de temporada. Además, estando fuera de temporada un 4 % de ellos también comentaron tomar algún medicamento para poder dormir mejor. Estos números aumentan significativamente a un 46 % y 17 % respectivamente cuando los atletas están en plena temporada de competición [4].

Adicionalmente, durante los últimos años se ha ido desarrollando el área de inteligencia artificial lo cual ha permitido el desarrollo de algoritmos clasificadores. En base a una colección de datos, los clasificadores pueden entrenarse para poder reconocer patrones y con esto poder tomar decisiones o realizar acciones automáticamente. Estos clasificadores se han utilizado para la clasificación de señales bioeléctricas. Esto es de gran importancia ya que utilizando estas herramientas se pueden obtener y clasificar las señales EEG producidas al dormir y con esto detectar en qué etapa de sueño se encuentra la persona.

En base a lo mencionado anteriormente lo que se busca con este proyecto es aprovechar las diferentes herramientas que se han desarrollado para poder generar una nueva que sea capaz de obtener y procesar las señales producidas al dormir. Todo esto con el fin de poder identificar las diferentes etapas del sueño a medida que estas se vayan dando.

Para ello se busca realizar pruebas con distintos tipos de clasificadores y características en diferentes dominios (Tiempo, frecuencia, estadístico) para poder observar los diferentes resultados que estos presenten y poder realizar la comparación entre ellos para ver cuales presentan mejores resultados con un costo computacional menor.

Objetivo General

Implementar técnicas y algoritmos de reconocimiento de patrones a señales biomédicas para su aplicación en un sistema inteligente de monitoreo de etapas de sueño.

Objetivos Específicos

- Obtener una colección de señales biomédicas relacionadas a etapas de sueño, según estándares internacionales.
- Analizar técnicas de selección de características y reconocimiento de patrones de señales biomédicas, y seleccionar aquellas que permitan la clasificación de las etapas de sueño.
- Aplicar las técnicas seleccionadas a la colección de señales obtenidas, y validar resultados mediante asesoría médica y comparación con estudios similares.
- Diseñar e implementar una herramienta de hardware y software que permita monitorear las etapas de sueño en tiempo real.

Este proyecto consiste en la realización de una segunda fase de un proyecto que se espera pueda ayudar a los atletas combatir desordenes del sueño mediante la utilización de pulsos binaurales. Para esta fase se concentrara la atención en la realización de un sistema que sea capas de analizar distintas señales biomédicas, principalmente señales Electroencefalográficas (EEG) y que pueda reconocer distintos patrones para la clasificación de las etapas del sueño en tiempo real. Cabe mencionar que este proyecto no es ninguna implementación final del proyecto, pero se espera que sea una buena base para futuras fases de este proyecto y así mas estudiantes puedan involucrarse no solo en el proyecto sino que también en el área a la cual esta enfocado.

El primer modulo de este proyecto consta en el desarrollo de un sistema que sea capas de obtener y procesar las señales EEG en tiempo real de manera eficiente, utilizando los distintos equipos que se tienen disponibles en la universidad. El segundo modulo consiste en el análisis y clasificación de las señales obtenidas en el modulo anterior y ser capaces de poder obtener distintos tipos de información de cada una de las señales para que con esta información poder emplear distintos tipos de clasificadores basados en los principios del aprendizaje automático para la clasificación de las etapas del sueño. Por ultimo el tercer modulo consiste en el almacenamiento eficiente de estas señales, debido a que son largas cadenas de datos es importante poder almacenar estos de manera que no ocupen tanto espacio y que al momento de querer consultarlos se pueda acceder fácilmente a ellos sin perder ningún dato en la descarga de ellos.

El producto de esta fase es un sistema que es capas de obtener y procesar señales para poder reconocer las distintas etapas del sueño de una persona de manera que esta las vaya experimentado, siguiendo con lo mencionando anteriormente y se espera que en futuras fases de este proyecto se pueda integrar a la generación de pulsos para poder tener un primer prototipo funcional y así poder seguir con el desarrollo de esta herramienta para poder llegar a ser implementada en el futuro.

6.1. Ondas cerebrales

La raíz de todos nuestros pensamientos, emociones y comportamientos es la comunicación entre las neuronas dentro de nuestros cerebros. Las ondas cerebrales son producidas por pulsos eléctricos sincronizados de masas de neuronas que se comunican entre sí. Las ondas cerebrales se detectan mediante sensores colocados en el cuero cabelludo. Se dividen en anchos de banda para describir sus funciones, pero se considera mejor como un espectro continuo de conciencia; desde lento, ruidoso y funcional, hasta rápido, sutil y complejo. Nuestras ondas cerebrales cambian de acuerdo con lo que estamos haciendo y sintiendo. Cuando las ondas cerebrales más lentas son dominantes, podemos sentirnos cansados, lentos, lentos o soñadores. Las frecuencias más altas son dominantes cuando nos sentimos conectados, o hiper-alerta[5].

La velocidad de transmisión de las ondas cerebrales se mide en hercios (ciclos por segundo) y se dividen en bandas que delimitan las ondas lentas, moderadas y rápidas.

6.1.1. Ondas Delta 0.5Hz a 4 Hz

Están asociadas a un estado de sueño profundo. En estas ondas la mente opera de forma totalmente integrada. Sus estados psíquicos correspondientes son el dormir sin sueños, el trance y la hipnosis profunda. Si se consigue entrar y permanecer consciente en el nivel delta, se alcanza el estado de superconsciencia que es el último peldaño de la meditación, donde desaparecen las barreras entre consciente, subconsciente e inconsciente[6].

6.1.2. Ondas Theta 4 Hz a 7 Hz

Estas ondas son producidas durante estados de meditación profunda y durante periodos de concentración intelectual. Las ondas Theta se asocian a un estado emocional cuyas características principales son la memoria plástica, la estimulación de la imaginación y creatividad y un incremento en la capacidad de aprendizaje[5].

6.1.3. Ondas Alfa 7 Hz a 12 Hz

Se las registran en los momentos antes de dormirse, se producen en un estado de no actividad y relajación mental. Son más lentas y de mayor amplitud[6].

6.1.4. Ondas Beta 13 Hz a 39 Hz

Este tipo de ondas están asociados a estados de actividad mental intensa, resolviendo problemas, estudiando, concentración o ansiedad. Es decir, se producen cuando el cerebro está despierto, cuando hay mayor extroversión, cuando hay actividades mentales y hay percepción a través de los cinco sentidos, así como también cuando se realiza trabajos del tipo físico o corporal. Es la más rápida de las cuatro [6].

6.1.5. Ondas Gamma 39Hz en adelante

Son las ondas más rápidas y de menor amplitud. Pueden aparecer en cualquier parte del cerebro y se asocian a estados donde una persona esta resolviendo problemas lógicos o matemáticos, favoreciendo el procesamiento de la información[5].




Figura 1: Ondas Cerebrales[5]

6.2. Señales binaurales

La palabra binaural significa "tener o relacionarse con dos oídos". Esto representa el proceso, que funciona enviando simultáneamente una frecuencia de sonido diferente a cada oído a través de los auriculares. El arrastre ocurre dentro del cerebro y es causado por una respuesta fisiológica. Al escuchar dos tonos de diferentes frecuencias, enviados simultáneamente a los oídos izquierdo y derecho, el cerebro percibe un nuevo tono, o tercer tono como algunos lo llaman, basado en la diferencia matemática entre las dos frecuencias. Luego, el cerebro sigue a la nueva frecuencia y produce ondas cerebrales a la misma velocidad de Hertz (Hz), quedando así arrastrado a esa frecuencia[7]. En la Audición Binaural los oídos forman canales receptores que son independientes entre sí, es decir, no hay interferencias entre ellos, ni combinaciones de las frecuencias recibidas por cada uno; los sonidos se reciben independientemente por cada oído y crean efectos diferentes en distintas partes del cerebro. Dentro de la audición binaural existen dos factores que determinan la dirección de llegada de un sonido: su intensidad relativa en los dos oídos y el intervalo de tiempo de llegada a los oídos. Para localizar una fuente de sonido, el sistema auditivo utiliza la diferencia de tiempo existente entre el sonido que llega al oído derecho y al izquierdo, conocido como ITD (Interaural Time Difference)[6].

Estos tonos son sonidos con un comportamiento sinusoidal, escuchados con un casco, tienden a sincronizar los dos hemisferios del cerebro. La diferencia de frecuencias induce dos efectos:

- Se comienza por decir que esta diferencia de frecuencias esta tratada en los núcleos olivarios superiores de cada hemisferio ellos producen asi ondas cerebrales de la misma frecuencia que la diferencia; estas nuevas ondas se propagan progresivamente a partir de estos núcleos en toda la corteza. Así pues, por ejemplo para hacer producir ondas alfa se hará escuchar sonidos que difieren de 8 a 13 Hz, lo que corresponde a la frecuencia de las ondas alfa[8].
- Estos sonidos permiten también sincronizar los dos hemisferios cerebrales , sincronización que induciría un estado de bienestar, una mejora del humor, mejores resultados atencionales y de memoria, un tratamiento de las emociones y una disminución de la ansiedad[8].

Los latidos binaurales pueden llevar al cerebro a diferentes estados del ser, de los cuales hay cinco categorías clave. El efecto que los ritmos binaurales tienen en el oyente depende del estado de la onda cerebral de la música[7].

Por ejemplo: para inducir una relajación profunda, podemos escuchar música de estado Theta, Para que el cerebro duerma más profundamente, podemos escuchar la música del estado de Delta[7].




Figura 2: categorías principales de estados de ondas cerebrales utilizadas en la música binaural beats y sus beneficios asociados [5]

La audición binaural permite al sistema auditivo realizar un correcto análisis de la información que portan las ondas sonoras al posibilitar la comparación de la señal que llega a cada oído. La relación de ambos lados de la vía auditiva sucede casi desde el inicio de la misma, ya en el tronco cerebral, mediante decusaciones de fibras al lado contralateral de la vía auditiva. De esta manera, la estimulación sonora influye en la actividad del sistema nervioso y, posteriormente, en el comportamiento del individuo. De hecho, pequeñas diferencias interaurales de frecuencia en un sonido que estimule bilateralmente al individuo inducen una sensación auditiva rítmica con una frecuencia de batido igual a la diferencia de frecuencias interaurales de los sonidos estimulantes[8].

6.3. El ciclo del sueño

Cuando una persona duerme su inconsciente va progresando a través de distintas etapas del sueño que conforman lo que se conoce como el ciclo del sueño. A las primeras cuatro etapas se les denomina como etapa 1, etapa 2, etapa 3 y etapa 4 y se clasifican como sueño NREM por el acrónimo que se forma con sus siglas en inglés (Non-Rapid Eye Movement), ya que durante estas etapas apenas existe movimiento ocular. Por otro lado, la última etapa es conocida y clasificada como la etapa REM también llamada así por sus siglas en inglés (Rapid Eye Movement). En esta etapa, al contrario de lo que ocurre en las etapas NREM, los ojos se mueven constante y rápidamente. A lo largo de toda la noche una persona atraviesa todas las etapas de manera cíclica, empezando por la etapa 1 y terminando en la etapa REM. Generalmente completar el ciclo del sueño dura entre 90-110 minutos, por lo que se recorre entre 4 y 6 veces por noche dependiendo de cuanto tiempo se duerma. Durante el transcurso de la noche cada etapa tiene una duración aproximada entre 5-15 minutos dependiendo de cuanto tiempo lleve la persona dormida. Comúnmente, durante los primeros ciclos las etapas de sueño REM son cortas con largos periodos de la etapa 4. Conforme avanza la noche la situación se revierte y el sueño REM aumenta su duración mientras que la etapa 4 aparece por menos tiempo e incluso llega a desaparecer en los últimos tramos de la noche[9].

Estas etapas pueden representarse con lo que se conoce como hipnograma el cual es un registro gráfico de las distintas etapas del sueño que se genera en base a las mediciones de señales bioeléctricas en el cuerpo mientras una persona duerme. Este gráfico es el que les permite a los expertos diagnosticar entre los distintos trastornos de sueño que hay. Un ejemplo de este puede apreciarse en la Figura 3 en la cual se muestra un diagrama del ciclo de una persona normal, en el que puede apreciarse la distribución de tiempo según cada etapa y más adelante se muestra más a detalle cada una de las diferentes etapas mencionadas anteriormente[9].




Figura 3: Hipnograma estándar del sueño

- Etapa I o de adormecimiento: Inicia al acostarnos, la somnolencia o sueño ligero, los músculos se relajan y las ondas cerebrales son irregulares y rápidas. Al producirse por primera vez durante la noche, suele pasar un lapso comprendido de 30 segundos a 7 min, en ella disminuye la frecuencia cardíaca y respiratoria. Se produce una onda theta y en esta etapa es fácil despertar al sujeto[10].
- Etapa II o de sueño ligero: ocupa aproximadamente el 50% de los ciclos de sueño. Generalmente ocupa el 20% de la noche y las ondas cerebrales son de mayor amplitud

y menor frecuencia. Es posible que pasen por la mente ideas fragmentadas o imágenes, pero no tenemos presencia de nuestro entorno y aunque nuestros ojos puedan estar abiertos, no podemos ver. Dura de 10 a 15 minutos, se produce una disminución de la temperatura y la tasa metabólica[10].

- Etapa III o de transición: es una etapa corta, de dos o tres minutos, que acerca al sueño profundo. Si la persona se despierta durante esta fase se puede sentir confusa. Es en ella en la que se dan también los terrores nocturnos, el sonambulismo y la micción. Las ondas predominantes son las delta. Durante las fases III y IV es cuando el cuerpo se encuentra en estado de profunda relajación y se dan los picos de segregación de la hormona del crecimiento[11].
- Etapa IV o sueño delta: suele ocupar un 20 % aproximadamente del total del ciclo de sueño. Es la etapa en la que se está profundamente dormido y se descansa física y psíquicamente. Por tanto, es la que determina la calidad del sueño. Durante esta fase también es difícil despertarse, y el ritmo respiratorio y la presión arterial son muy bajos[11].
- Etapa REM (Rapid Eye Movement, Movimiento Rápido del Ojo) o etapa del sueño paradójico: ocupa un 25 % del ciclo total de sueño, entre 15 y 30 minutos. Se denomina así por el movimiento constante de los globos oculares bajo los párpados. Esta fase se caracteriza por tener una alta actividad cerebral, similar a la que se tiene cuando la persona está despierta. El ritmo cardíaco y la presión arterial suben pero los músculos se encuentran bloqueados. En ella se tienen los sueños en forma de historia y, si nos despiertan, somos capaces de recordarlos. Las ondas predominantes son las theta[11].

6.4. Electro - Cap

Electro-Caps son una técnica de aplicación de electrodos EEG. Están hechas de una tela elástica tipo spandex con electrodos empotrados de estaño puro unidos a la tela. Los electrodos en las tapas estándar se colocan según el método internacional 10-20 de colocación de electrodos[12].



Figura 4: Electro Cap y sus componentes[12]

El Electro-Cap posee una terminal DB-25 donde se puede acceder a los distintos electrodos que se encuentran incorporados en el gorro, los cuales en algunos modelos es necesario conseguirlos por aparte. A continuación se presenta un cuadro detallando la distribución e interconexión de los pines con los electrodos[12].

6.5. Sistema Internacional 10-20

Este método determina la distancia entre los electrodos en forma porcentual, de ahí el nombre de 10-20 ya que los electrodos están separados entre sí por 10 o 20 % de una distancia determinada. La razón de utilizar porcentajes en vez de longitud es el hecho de que el tamaño del cráneo varía de una persona a otra[13].

Para colocar los electrodos de acuerdo con el sistema 10-20 se requiere realizar las siguientes mediciones que sirven de referencia para obtener los porcentajes 10 y 20 . Se mide la distancia que hay entre el inión y el nasión, que representa 100 % en el plano sagital, y la distancia entre el trago de un lado y el trago del lado opuesto, que es 100 % en sentido coronal. El electrodo central Cz se ubica a la mitad de la distancia entre el inión y el nasión (50 %), y a la mitad de la distancia trago-trago (50 %)[13].

Un 20 % de la distancia inión-nasión, hacia adelante de Cz y en la línea media, corresponde a la ubicación del electrodo Fz, y 20 % hacia atrás de Cz se ubica Pz. En dirección lateral a Cz se encuentran del lado derecho C4 y T4, al 20 y 40 % de la distancia trago-trago, respectivamente, y del lado izquierdo están C3 y T3, también al 20 y 40 % de la distancia trago-trago. Como se puede ver, la ubicación de los electrodos se determina con una letra y un número; las letras hacen referencia al lóbulo cerebral sobre el que se coloca el electrodo: F, P, T y O para frontal, parietal, temporal y occipital. La letra C se refiere al plano coronal

| Pin | Ubicación | Color |
|-----|-----------|----------|
| 1 | FP1 | Café |
| 2 | F3 | Rojo |
| 3 | C3 | Naranja |
| 4 | P3 | Amarillo |
| 5 | O1 | Verde |
| 6 | F7 | Azul |
| 7 | T3 | Morado |
| 8 | T5 | Gris |
| 9 | GND | Blanco |
| 10 | FZ | Negro |
| 11 | A1 | - |
| 12 | OZ | - |
| 13 | - | - |
| 14 | FP2 | Café |
| 15 | F4 | Rojo |
| 16 | C4 | Naranja |
| 17 | P4 | Amarillo |
| 18 | O2 | Verde |
| 19 | F8 | Azul |
| 20 | T4 | Morado |
| 21 | T6 | Gris |
| 22 | CZ | Blanco |
| 23 | PZ | Negro |
| 24 | A2 | - |

Cuadro 1: Pines de salida del Electro-Cap[12]

y no corresponde a lóbulo alguno. A continiacion se presenta una representacion grafica de como se colocan los electrodos con este sistema[13].




Figura 5: Ubicación de electrodos según el Sistema Internacional 10-20[13]

6.6. OpenBCI

OpenBCI es una plataforma/comunidad de interfaz cerebro-computadora de código abierto o mas conocida como Open Source ,de investigadores, ingenieros, científicos, etc. que tienen como objetivo que todos aquellos que tengan pasión e interés en las señales eléctricas del cuerpo y cerebro humano tengan a su alcance las herramientas necesarias para descubrir nuevas cosas acerca de su comportamiento. Esta comunidad provee de sistemas que pueden ser usados para monitorear la actividad cerebral (EEG), la actividad muscular (EMG) y la actividad cardiaca (ECG). Además de estos sistemas, esta comunidad también proveen de tutoriales y software para poder utilizar sus equipos correctamente y tener una interfaz amigable donde se puedan interactuar con las mediciones[14].

Específicamente para la parte de la EEG tienen a disposición cascos y gorros con electrodos para monitorear las ondas cerebrales. Incluso tienen disponibles los diseños de sus cascos y placas para que una persona los pueda replicar por su cuenta como una opción más económica. Por otro lado, también cuentan con una interfaz de usuario a cual entre una de sus opciones permite observar las mediciones en tiempo real la cual se llama OpenBCI_GUI, esta se puede observar en la siguiente figura[14].




Figura 6: Interfaz grafica de OpenBCI [14]

6.7. Cyton Board y Dongle

OpenBCI Cyton Board es una interfaz neuronal de 8 canales compatible con Arduino con un procesador de 32 bits. En esencia, la placa OpenBCI Cyton implementa el microcontrolador PIC32MX250F128B, lo que le brinda mucha memoria local y velocidades de procesamiento rápidas. La placa viene preinstalada con el gestor de arranque chipKIT y el último firmware OpenBCI[15].

Los datos se muestrean a 250Hz en cada uno de los ocho canales. OpenBCI Cyton Board se puede utilizar para tomar muestras de actividad cerebral (EEG), actividad muscular (EMG) y actividad cardíaca (ECG)[15]. La Cyton Board cuenta con los siguientes aspectos técnicos:

- 8 canales de entrada diferenciales, de alta ganancia y bajo ruido
- Compatible con electrodos activos y pasivos
- ADC ADS1299 de Texas Instruments
- Microcontrolador PIC32MX250F128B
- Módulo RFduino BLE para comunicación Bluetooth
- 24 bits de resolución en el canal de datos
- Ganancia programable: 1, 2, 4, 6, 8, 12, 24
- Voltaje de operación digital de 3.3V
- Voltaje de operación analógico de $\pm 2.5V$
- Voltaje de entrada de 3.3 a 12V
- Acelerómetro LIS3DH
- Ranura para tarjeta micro SD

- 5 pines GPIO, 3 de los cuales pueden ser analógicos




Figura 7: Cyton Boarde de OpenBCI [15]

En la figura anterior se puede apreciar ambos lados de la Cyton board y como es que se encuentran distribuidos sus componentes. Para poder realizar la comunicación entre la placa y la computadora se utiliza un dispositivo intermediario conocido como Dongle, dicho dispositivo se puede observar a detalle más adelante. Este módulo encarga de recibir los datos de la Cyton Board por medio de una conexión inalámbrica con Bluetooth, por lo cual ambos dispositivos cuentan con un módulo de Arduino llamado RFduino BLE que permite establecer este tipo de comunicación. Con el RFduino BLE se pueden conseguir mayores tasas de transmisión que con los módulos convencionales. Posteriormente el Dongle de OpenBCI transmite los datos recibidos por el puerto serial de la computadora o procesador con un baudaje de 115200 [15]. El Dongle cuenta con los siguientes aspectos técnicos:

- Módulo de radio RFD22301 de RFDigital
- Convertidor de USB a serie FT231X de FTDI
- Módulo RFduino BLE para comunicación Bluetooth
- Alimentación vía USB (Únicamente)




Figura 8: Dongle de OpenBCI [15]

6.8. Machine Learning

Un subconjunto de la inteligencia artificial (IA), el aprendizaje automático (*Machine Learning* - ML) es el área de la ciencia computacional que se centra en el análisis y la interpretación de patrones y estructuras de datos que hacen posible el aprendizaje, el razonamiento y la toma de decisiones sin interacción humana. Dicho de otro modo, el aprendizaje automático permite que el usuario alimente un algoritmo informático con una cantidad ingente de datos, a partir de los cuales el ordenador analiza toda la información y es capaz de tomar decisiones y hacer recomendaciones basándose únicamente en los datos introducidos. En el caso de identificar correcciones, el algoritmo puede incorporar esa información para mejorar la toma de decisiones futura[16]. El aprendizaje automático consta de tres partes:

- El algoritmo computacional, situado en el núcleo de la toma de determinaciones.
- Las variables y las funciones que conforman la decisión.
- El conocimiento base según el cual se sabe la respuesta que permite aprender al sistema.

Inicialmente, el modelo se alimenta de datos de parámetros para los que se conoce la respuesta. Se ejecuta entonces el algoritmo y se realizan ajustes hasta que el resultado del

algoritmo coincide con la respuesta conocida. En este momento, se va aumentando la cantidad de datos que se introducen para ayudar al sistema a aprender y procesar un número mayor de decisiones computacionales[16].

6.8.1. Red Neuronal Artificial

El primer modelo matemático de una neurona artificial, creado con el fin de llevar a cabo tareas simples, fue presentado en el año 1943 en un trabajo conjunto entre el psiquiatra y neuroanatomista Warren McCulloch y el matemático Walter Pitts[17].

La siguiente figura muestra un ejemplo de modelo neuronal con n entradas, que consta de:

- Un conjunto de entradas x_1, \dots, x_n .
- Los pesos sinápticos w_1, \dots, w_n , correspondientes a cada entrada.
- Una función de agregación.
- Una función de activación, f .
- Una salida, Y .

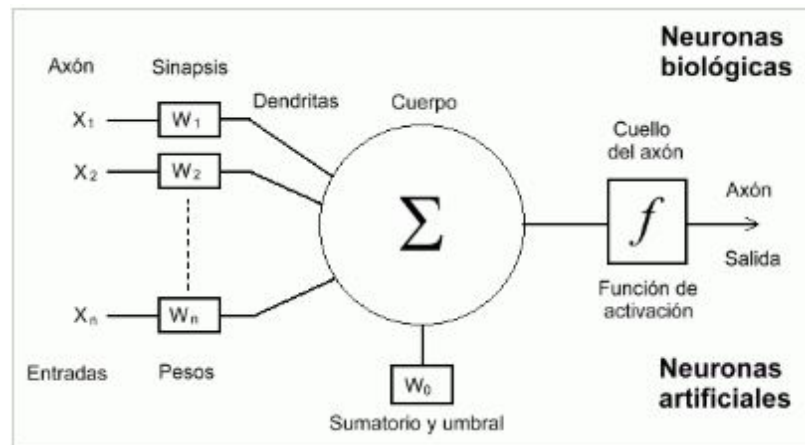


Figura 9: Modelo de la neurona artificial [17]

Las entradas son el estímulo que la neurona artificial recibe del entorno que la rodea, y la salida es la respuesta a tal estímulo. La neurona puede adaptarse al medio circundante y aprender de él modificando el valor de sus pesos sinápticos, y por ello son conocidos como los parámetros libres del modelo, ya que pueden ser modificados y adaptados para realizar una tarea determinada[17].

En este modelo, la salida neuronal Y está dada por:

$$Y = f\left(\sum_i^N w_i x_i\right)$$

Ya habiendo definido y mostrado la estructura de una neurona artificial, ya se puede definir una Red Neuronal Artificial (RNA), la cual es un modelo matemático inspirado en el comportamiento biológico de las neuronas y en cómo se organizan formando la estructura del cerebro. El cerebro puede considerarse un sistema altamente complejo, donde se calcula que hay aproximadamente 100 mil millones (1011) neuronas en la corteza cerebral (humana) y que forman un entramado de más de 500 billones de conexiones neuronales[17].




Figura 10: Modelo de la neurona artificial [18]

El objetivo de las redes neuronales es emular las siguientes funcionalidades de una red biológica:

- Procesamiento en paralelo: Las redes de neuronales son capaces de operar en paralelo un proceso producto de la gran cantidad de neuronas que intervienen en dicho proceso.
- Memoria distribuida: En estas redes no hay posiciones de memoria definidas si no que la información se distribuye a lo largo de la red, existiendo redundancia para evitar la pérdida de información.
- Adaptabilidad: Las redes de neuronales son capaces de aprender de la experiencia, siendo capaces de modificar su comportamiento en respuesta a su entorno.

Por estas funcionalidades y muchas otras más las redes neuronales son común en el proceso de reconocimiento de patrones. En dicho proceso se entrena una red neuronal para asignar clases determinadas a un conjunto de entradas. Dadas las características de la red, una vez entrenada es capaz de clasificar y aprender de patrones que nunca antes había visto.

Las redes neuronales pueden ser sometidas a distintos tipos de entrenamientos ya sea de aprendizaje supervisado o no supervisado en donde:

6.8.2. Aprendizaje Supervisado

El aprendizaje supervisado se caracteriza por la presencia de un agente externo que controla el proceso de entrenamiento, estableciendo la respuesta que debería generar la red

a partir de una entrada determinada. De esta forma el supervisor comprueba la salida de la red, la compara con la salida deseada y, si existen diferencias, ajusta iterativamente los pesos hasta que su salida tiende a ser la deseada [18].

Este tipo de aprendizaje se puede subdividir en tres tipos los cuales son:

- **Aprendizaje por corrección de error**
Este tipo constituye el tipo de aprendizaje supervisado mas utilizado en la práctica. Su funcionamiento se basa en el ajuste de pesos de las conexiones de la red a partir de la diferencia entre los valores deseados y los obtenidos por el sistema, esto es, en función del error cometido en la salida[18].
- **Aprendizaje por refuerzo**
En este tipo de aprendizaje la tarea del supervisor se limita a indicar, mediante una señal de refuerzo ($\text{Éxito} = +1$ o $\text{fracaso} = -1$), si la salida obtenida por la red se ajusta o no a la deseada y, en función de ello, se procede al ajuste de los pesos utilizando un mecanismo basado en probabilidades, por lo que este tipo de aprendizaje también se denomina de “premio – castigo”.
Este aprendizaje resulta mas lento que el aprendizaje por corrección de error, al no indicar de forma expresa al sistema la salida que se desea ante una determinada entrada, por lo que el supervisor actúa mas como un critico que como un maestro[18].
- **Aprendizaje estocástico**
Este tipo de aprendizaje se basa en la introducción de cambios aleatorios en los valores de los pesos de la red, evaluando su efecto a partir de la salida deseada y de una distribución de probabilidad. En el aprendizaje estocástico suele establecerse una analogía en términos termodinámicos, asociando la red con un sólido físico que presenta cierto estado energético, por lo que el aprendizaje consiste en minimizar la energía del sistema a través del ajuste de los pesos. Para ellos, se realizan los cambios estocásticos de los valores de los pesos, determinándose la energía de la red tras estas modificaciones; si la energía es menor después del cambio, se acepta la modificación; si la energía no es menor, la aceptación del cambio depende de una distribución de probabilidad determinada y preestablecida[18].

| Tipo de aprendizaje supervisado | | Modelo de red |
|-------------------------------------|----------|---------------------------|
| Aprendizaje por corrección de error | Off-line | Perceptrón |
| | | Adaline/Madaline |
| | | Backpropagation |
| | | Brain-State-in-a-Box |
| Aprendizaje por refuerzo | On-line | Linear Reward Penalty |
| | | Adaptive Reward Penalty |
| | | Adaptive Heuristic Critic |
| Aprendizaje estocástico | Off-line | Boltzmann Machine |
| | | Cauchy Machine |

Figura 11: Principales modelos de RNAs con aprendizaje supervisado [18]

6.8.3. Aprendizaje no supervisado

Aprendizaje no supervisado Las redes con aprendizaje no supervisado o requieren de información externa para ajustar los pesos de las conexiones neuronales. En el aprendizaje no supervisado se presenta a la red un conjunto de patrones sin adjuntar la respuesta deseada por lo que la red, por medio del algoritmo de aprendizaje, estima la función de densidad probabilística que describe la distribución de patrones. Para ello, el sistema reconoce las peculiaridades, correlaciones o categorías presentes en el conjunto de entradas, extrayendo los rasgos o agrupando patrones según su similitud. Para que la red obtenga resultados de calidad, es necesario un cierto nivel de redundancia en las entradas presentadas al sistema, esto es, debe disponerse de un número suficiente de patrones de aprendizaje[18].

Una vez realizada la fase de investigación y tener claros los objetivos que se deseaban lograr, era importante buscar no solo como lograr que Matlab obtuviera los datos de la Cyton Board en tiempo real, sino que también poder encontrar una colección de datos con los cuales poder realizar distintas pruebas con los clasificadores. Uno de los recursos que se encontró y ya había sido utilizado en la fase anterior de este proyecto fue la base de datos llamada Physionet, la cual posee una amplia colección de datos y señales biomédicas. Una de sus principales ventajas es que esta posee mediciones de las etapas del sueño con las distintas etapas ya clasificadas por expertos en esas áreas. Teniendo esto en cuenta se decidió utilizar estas mediciones, pero al hacerlo surgió el problema de que los formatos que se utilizan en el campo de señales EEG no son entendibles por Matlab ya que se utiliza el formato .edf, entonces se comenzó a buscar la manera de poder realizar la conversión de este formato a uno que Matlab pudiera interpretar. Luego de un tiempo se encontró una herramienta que descarga y convierte todos los datos y anotaciones dentro de la base de datos de physionet. Esta herramienta se llama **Sleep EDFx Toolbox** y puede ser encontrada en github con las distintas indicaciones para poder implementarla.

7.1. Familiarización con la Cyton Board y el Elettro - cap

Una vez obtenidas distintas mediciones de la base de datos para poder probar los distintos clasificadores era necesario empezar a conocer y explorar el funcionamiento y comunicación entre la cyton board por lo que se utilizó la herramienta de OpenBCI_GUI, la cual es propia de la empresa que fabrica la cyton board y ha sido utilizada en los distintos proyectos anteriores a este para verificar el funcionamiento del equipo y así saber qué tipos de datos se trabajan y la forma en la que este los obtiene.



Figura 12: Captura de gestos para la verificación de funcionamiento

Como se puede apreciar en la figura anterior, al realizar ciertos gestos, se van generando distintos pulsos en los diferentes canales que se tienen, en este caso se tienen 8 canales.

7.2. Conexión Matlab – Cyton Board

Ya con el conocimiento de cómo se debían de ver las señales de la Cyton se pasó a investigar la manera de obtener los datos mediante Matlab para poder procesarlos y así poderlos utilizar más adelante y al revisar la documentación dentro del sitio web de OpenBCI se encontró una herramienta de Python que permite la comunicación con la Cyton y así poder transmitirla a Matlab de manera inmediata utilizando *lab streaming layer*.

Ya teniendo la comunicación con Matlab se debía de procesar los datos, ya que estos se envían de manera “cruda” y no pueden ser utilizados de manera inmediata por lo que se le aplico dos tipos de filtros, los cuales fueron un pasa banda que permitiera señales entre 0.5 y 50 Hz y un filtro rechaza banda de 60 Hz para eliminar el desfase DC.

Ya con el filtrado hecho se realizaron pruebas de la misma manera que se realizaron con el programa de OpenBCI pero esta vez usando dicho programa para verificar el funcionamiento adecuado de los distintos canales. Uno de los ejercicios que se realizo para verificar el funcionamiento fue el de remachar los dientes en distintas ocasiones y así comparar los resultados, los cuales quedaron de la siguiente manera:




Figura 13: Captura de gestos del canal 1 y 2 utilizando el programa desarrollado.




Figura 14: Captura de gestos del canal 3 y 4 utilizando el programa desarrollado.




Figura 15: Captura de gestos del canal 5 y 6 utilizando el programa desarrollado.




Figura 16: Captura de gestos del canal 7 y 8 utilizando el programa desarrollado.




Figura 17: Captura de gestos de los 8 canales utilizando OpenBCI_GUI.

Como se puede observar los resultados obtenidos por Matlab son bastante similares con los obtenidos en la interfaz de OpenBCI por lo que esto ayudo a corroborar el funcionamiento adecuado del sistema y así poder pasar a realizar las distintas pruebas.

7.2.1. Indicadores para la clasificación de señales

Ya teniendo una respuesta adecuada a distintos gestos realizados se realizo un análisis mas extenso para verificar que la obtención fuera lo mas adecuada posible. En base a eso se considero uno de los factores que se toman en a la hora de la clasificación de señales y este es el cambio de frecuencias que se dan durante el transcurso del sueño, por lo que se realizo una prueba que tuvo una duración de aproximadamente 2 horas para verificar el cambio de frecuencias y se obtuvieron las siguientes señales, las cuales se acercan al comportamiento esperado acorde a los distintos tipos de ondas




Figura 18: Ondas Gamma obtenidas con el programa en Matlab.




Figura 19: Ondas Beta obtenidas con el programa en Matlab.




Figura 20: Ondas Delta obtenidas con el programa en Matlab.

Ya teniendo un comportamiento cercano a lo requerido se pudo a pasar al siguiente paso, el cual era la clasificación en tiempo real

8.1. señales de prueba

Como se mencionó en el capítulo anterior se obtuvieron las señales de prueba de la base de datos Physionet y con estos poder trabajar con distintos clasificadores. Para este proyecto se escogieron tres clasificadores distintos para ver cuales presentan mejores resultados y así explorar sus distintas ventajas y desventajas.

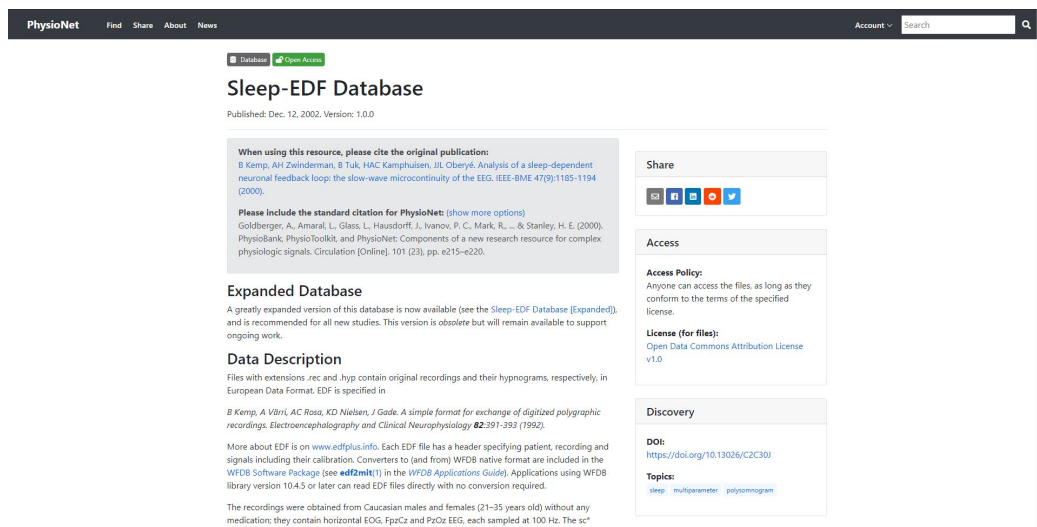


Figura 21: Vista de la pagina de donde se obtuvieron los datos.

Files

Total uncompressed size: 314.6 MB.

Access the files

- Download the ZIP file (314.6 MB)
- Access the files using the Google Cloud Storage Browser [here](#). Login with a Google account is required.
- Access the data using Google Cloud "gsutil": `gsutil -m cp -r gs://sleep-edf-1.0.0.physionet.org DESTINATION`
- Download the files using your terminal: `wget -r -N -c -np https://physionet.org/files/sleep-edf/1.0.0/`

[Visualize waveforms](#)

| Folder Navigation: <base> | | | |
|---------------------------|--|---------|------------|
| Name | | Size | Modified |
| RECORDS | | 208 B | 2012-02-25 |
| SHA256SUMS.txt | | 1.3 KB | 2019-02-20 |
| sc4002e0.hyp | | 6.0 KB | 2002-12-09 |
| sc4002e0.rec | | 49.2 MB | 2007-09-11 |
| sc4012e0.hyp | | 6.1 KB | 2002-12-09 |
| sc4012e0.rec | | 49.6 MB | 2007-09-11 |
| sc4102e0.hyp | | 6.1 KB | 2002-12-09 |
| sc4102e0.rec | | 49.7 MB | 2007-09-11 |
| sc4112e0.hyp | | 5.9 KB | 2002-12-09 |
| sc4112e0.rec | | 48.4 MB | 2007-09-11 |
| st702j0.hyp | | 3.1 KB | 2002-12-09 |
| st702j0.rec | | 31.1 MB | 2002-12-09 |
| st705j0.hyp | | 3.0 KB | 2002-12-09 |
| st705j0.rec | | 30.3 MB | 2002-12-09 |
| st712j0.hyp | | 2.9 KB | 2002-12-09 |
| st712j0.rec | | 29.2 MB | 2002-12-09 |
| st713j0.hyp | | 2.8 KB | 2002-12-09 |
| st713j0.rec | | 27.2 MB | 2002-12-09 |

Figura 22: Archivos de datos disponibles.

Entonces ya que se tuvieron los datos listos , se paso a analizar las diferentes características que se le pueden extraer a este tipo de señales en distintos dominios, tales como el dominio del tiempo, el de frecuencia y uno que es utilizado frecuentemente, el estadístico. Se utilizaron varios dominios debido a que de esta manera se obtiene una mayor información de la señal para poder realizar una buena clasificación

Ya habiendo decidido que características extraer, se paso a desarrollar los tres clasificadores que se deseaban poner en practica utilizando las herramientas de *deep learning* y *machine learning* que se tienen disponibles en Matlab. Esto permite poder trabajar de manera sencilla cada uno de los clasificadores, logrando hacer validación cruzada para observar el porcentaje de error en la clasificación, además de poder generar las matrices de confusión para observar de mejor manera como se clasifico cada uno de los datos obtenidos anteriormente. Mas adelante se podrá apreciar algunos de los resultados que se obtuvieron al realizar distintas pruebas con los clasificadores realizando distintas variaciones en la cantidad de datos y características utilizadas.

8.2. señales en tiempo real

Almacenamiento de las señales

Ya que parte de este proyecto requería de una manera de poder almacenar todas las mediciones que se fueran realizando durante el desarrollo del proyecto, por lo que se vio en la necesidad de desarrollar una base de datos en donde no solo se almacenaran los valores crudos o procesados de las mediciones, sino que también las diferentes características obtenidas para así poder ser utilizadas en futuros análisis.

9.1. Búsqueda de alternativas

Ya que no se tenían conocimientos previos de como realizar una base de datos se tuvo que realizar una investigación previa para ver cuales eran las diferentes opciones disponibles, ya fuera para realizar el almacenamiento de manera local o en algún servidor online.

9.1.1. FireBase

La primera opción que se encontró fue el servicio de almacenamiento FireBase de Google, el cual permite diferentes acciones de almacenamiento en tiempo real en servidores online, con la facilidad de poder acceder a ella a partir de diferentes herramientas tales como la programación en Python, Java y Node además de poder enlazar una pagina web a ella para hacerla más interactiva y útil.

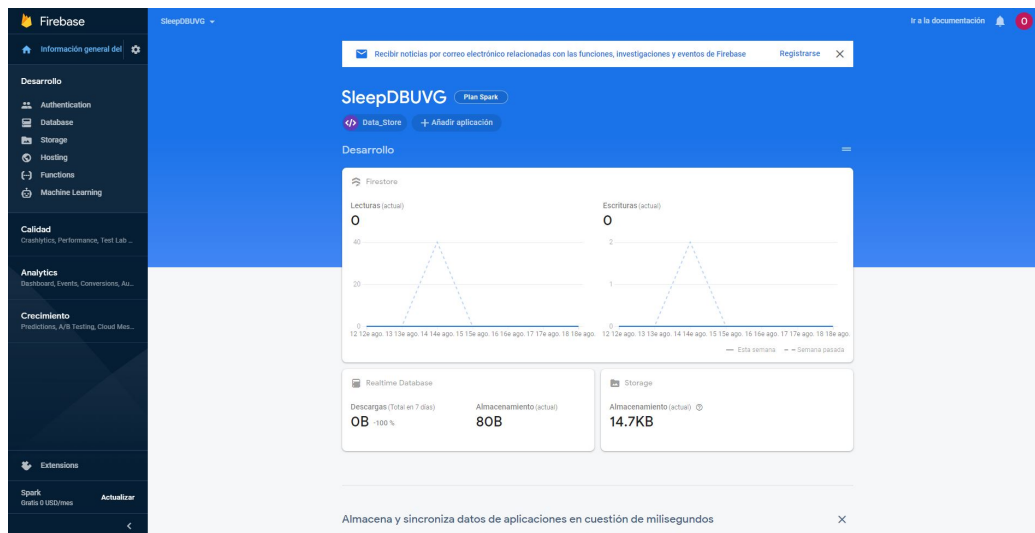


Figura 23: Pagina de inicio de FireBase.

En la figura anterior se puede apreciar la pagina principal de la base de datos en donde se muestra toda la información de consultas y la cantidad de data que se encuentra almacenada junto con la cantidad de consultas realizadas.

Uno de los problemas que se encontró al realizar distintas pruebas con esta base de datos fue que al cargar los diferentes datos de las mediciones, al ser vectores demasiado grandes no se almacenaban todos los datos de manera correcta ya que por el tamaño la pagina los acortaba el vector y solo representaba el tamaño con el uso de tres puntos y esto afectaba la descarga de estos datos ya que estos se descargaban de manera resumida y con los tres puntos, entonces se perdía casi toda la información, por esta razón fue que no se decidió utilizar esta plataforma a pesar de las diferentes ventajas que esta ofrece.

9.1.2. MySQL.

La segunda opción que se exploró fue MySQL, el cual la herramienta mas utilizada para la realización de base de datos y ofrece una amplia variedad de beneficios con respecto a su construcción y uso. Uno de los beneficios es que se puede realizar la estructuración de la base de datos de manera rápida y fácil. Además de que ofrece la capacidad de ingresar los datos en distintos formatos tales como Varchar, JSON, etc. . .

Para esta opción se tomó la decisión de realizarla de manera local, con la posibilidad de poder adecuarla para poder ser almacenada online en el futuro. Lo cual en comparación con la herramienta anterior resulto más sencilla la comunicación y la manera en la que se almacenan los datos. Al tener resultados bastante complacientes respecto al rendimiento y posibilidades se decidió utilizar esta herramienta y así poder continuar a almacenar las distintas pruebas.

9.2. Desarrollo de la base de datos.

Ya habiendo decidido la herramienta que se utilizaría se comenzó a ver la manera de almacenar de almacenar las amplias cadenas de datos de manera eficiente y funcional, ya que no todas las alternativas son funcionales para este tipo de datos. Ya que previamente se había decidido que el almacenamiento seria local, se opto en almacenar la dirección de cada archivo con los datos para evitar realizar operaciones computacional-mente pesadas debido a las largas cadenas de datos que se trabajan y así a la hora de realizar consultas solo es necesario obtener la dirección para poder llegar a los datos y así poder leer los datos de manera mas rápida y eficiente.

Ya con todo lo anterior definido se paso a realizar la base de datos la cual se dividió en dos tablas, una tabla dedicada a almacenar los datos de las mediciones del sueño y otra tabla para poder almacenar los datos de mediciones adicionales, como distintos gestos que se utilizaron para validar el funcionamiento de la conexión entre la cyton board y Matlab, además de que estos pueden ser utilizados para distintas aplicaciones y proyectos.

| Mov_ID | Mov_F1 | Mov_F2 | Mov_F3 | Mov_F4 |
|--------------------------------|---|---|---|---|
| 1 | | | | |
| Remachando los dientes | C:/Users/Public/SleepDatabase/Remachando los dent... | C:/Users/Public/SleepDatabase/Remachando los dent... | C:/Users/Public/SleepDatabase/Remachando los dent... | C:/Users/Public/SleepDatabase/Remachando los dent... |
| Levantamiento de cejas | C:/Users/Public/SleepDatabase/Levantamiento de cej... | C:/Users/Public/SleepDatabase/Levantamiento de cej... | C:/Users/Public/SleepDatabase/Levantamiento de cej... | C:/Users/Public/SleepDatabase/Levantamiento de cej... |
| Girando la cabeza a la derecha | C:/Users/Public/SleepDatabase/Girando la cabeza a ... | C:/Users/Public/SleepDatabase/Girando la cabeza a ... | C:/Users/Public/SleepDatabase/Girando la cabeza a ... | C:/Users/Public/SleepDatabase/Girando la cabeza a ... |
| Cerrando ojo izquierdo | C:/Users/Public/SleepDatabase/Cerrando ojo izquier... | C:/Users/Public/SleepDatabase/Cerrando ojo izquier... | C:/Users/Public/SleepDatabase/Cerrando ojo izquier... | C:/Users/Public/SleepDatabase/Cerrando ojo izquier... |

Figura 24: Vista del almacenamiento de gestos pt1.

| Mov_F5 | Mov_Filt | Mov_Descrip | Mov_Raw |
|---|---|---|---|
| C:/Users/Public/SleepDatabase/Remachando los dent... | C:/Users/Public/SleepDatabase/Remachando los dent... | 4 repeticiones del movimiento con duracion de 3 se... | C:/Users/Public/SleepDatabase/Remachando los dent... |
| C:/Users/Public/SleepDatabase/Levantamiento de cej... | C:/Users/Public/SleepDatabase/Levantamiento de cej... | 4 repeticiones del movimiento con duracion de 2 se... | C:/Users/Public/SleepDatabase/Levantamiento de cej... |
| C:/Users/Public/SleepDatabase/Girando la cabeza a ... | C:/Users/Public/SleepDatabase/Girando la cabeza a ... | 4 repeticiones del movimiento con duracion de 3 se... | C:/Users/Public/SleepDatabase/Girando la cabeza a ... |
| C:/Users/Public/SleepDatabase/Cerrando ojo izquier... | C:/Users/Public/SleepDatabase/Cerrando ojo izquier... | 4 repeticiones del movimiento con duracion de 3 se... | C:/Users/Public/SleepDatabase/Cerrando ojo izquier... |

Figura 25: Vista del almacenamiento de gestos pt2.

En las figuras anteriores se muestran algunos gestos que se almacenaron y de como es que se distribuyeron cada uno de los vectores de datos en donde las columnas F1 - F5 representan cada una de las características o features que se le extrajeron a las señales , las columnas de Raw y Filt almacenan los datos en bruto y los datos filtrados y por ultimo las columnas de

ID y Descrip son las columnas que almacenan la información de que gesto se realizó y una descripción mas detallada de las pruebas.

10.1. Pruebas offline

Para esta sección se buscaba poder comenzar con la prueba de clasificación de señales utilizando dos tipos de clasificadores, los cuales fueron maquinas de vectores de soporte (SVM) y redes neuronales. A los cuales se les aplicaron señales obtenidas de una base de datos publica la cual se llama Physionet.

Para poder empezar a utilizar los clasificadores era necesario hacer la conversión del formato utilizado en la base de datos a un formato que MATLAB pudiera interpretar, para esto se implementaron las funciones de *sleep-edfx-toolbox*, estas se encargan de descargar, convertir y procesar las señales y etiquetas de la base de datos para poder ser utilizadas. Estas funciones pueden ser encontradas en el siguiente enlace: <https://github.com/anasimtia/sleep-edfx-toolbox>

Ya habiendo logrado convertir los datos se pasó a extraer distintas características para poder pasar a la clasificación de las señales, las características que se seleccionaron para estas pruebas fueron:

1. Mean Absolute Value.
2. Zero Crossing.
3. Max Min Distance
4. Slow wave activity
5. Curtosis

10.1.1. Primeras pruebas

Para estas pruebas se trabajó con un solo canal de información y con solo tres características las cuales fueron: Zero Crossing, Mean absolute value y min max distance. Para la red neuronal se obtuvieron los siguientes resultados:

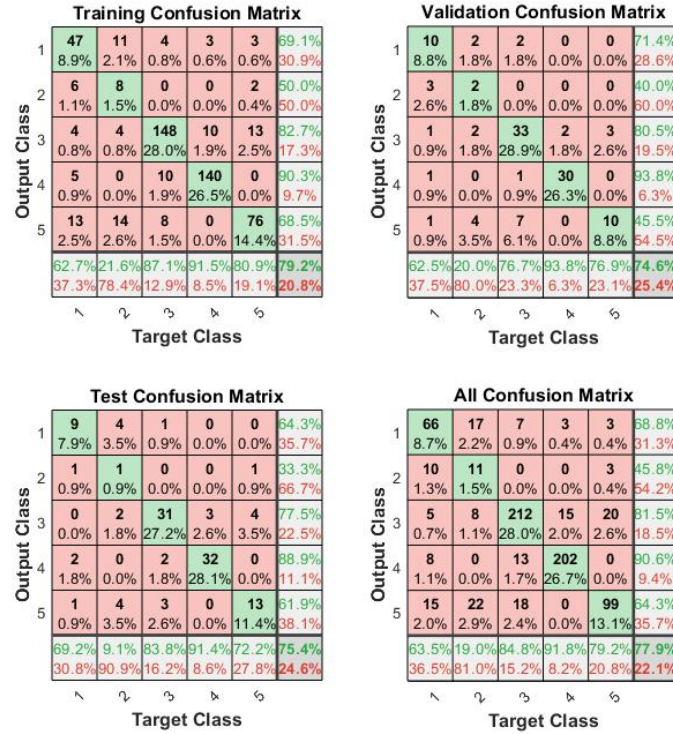


Figura 26: Matrices de confusión para la red neuronal con un canal de datos.

Para el caso de las maquinas de vectores de soporte y el clasificador de k- nearest neighbor, se tomaron dos formas de validación para poder verificar la funcionalidad y efectividad, las cuales fueron: la validación cruzada y las matrices de confusión.

Para el clasificador de vectores de soporte se trabajó con un kernel lineal, con lo que se obtuvieron los siguientes resultados:

| | | | | | | | | |
|------------|---|----|---|-----|-----|-----|-----------------|------|
| True Class | 1 | 79 | 3 | 7 | 4 | 11 | 10.4% | 3.3% |
| | 2 | 23 | | 6 | | 29 | | 7.7% |
| | 3 | 6 | | 215 | 11 | 18 | 28.4% | 4.6% |
| | 4 | 3 | | 8 | 209 | | 27.6% | 1.5% |
| | 5 | 5 | | 14 | | 106 | 14.0% | 2.5% |
| | | 1 | 2 | 3 | 4 | 5 | Predicted Class | |

Figura 27: Matrices de confusión para la maquina de vectores de soporte con kernel Lineal con un canal de datos.

y al aplicar la validación cruzada se obtuvo un porcentaje de error de 19.5509 %

Para el clasificador de k- nearest neighbor se trabajo con un valor de 10 para el numero de vecinos, el cual fue el valor que mejores resultados presento, los cuales fueron:

| | | | | | | | | |
|------------|---|----|---|-----|-----|----|-----------------|------|
| True Class | 1 | 75 | 4 | 10 | 7 | 8 | 9.9% | 3.8% |
| | 2 | 21 | 7 | 10 | | 20 | 0.9% | 6.7% |
| | 3 | 5 | 2 | 217 | 11 | 15 | 28.7% | 4.4% |
| | 4 | 3 | | 10 | 207 | | 27.3% | 1.7% |
| | 5 | 3 | 6 | 23 | | 93 | 12.3% | 4.2% |
| | | 1 | 2 | 3 | 4 | 5 | Predicted Class | |

Figura 28: Matrices de confusión para k- nearest neighbor con un canal de datos.

y al aplicar la validación cruzada se obtuvo un porcentaje de error de 20.8719 %

10.1.2. Pruebas posteriores

Luego de ver los resultados al aplicar tres características y un canal, se quería observar que resultados se obtendrían si se utilizaran mas canales y más características por lo que se implementaron dos características más, las cuales son Curtosis y slow wave activity, con lo que se obtuvieron los siguientes resultados: Para la red neuronal se obtuvieron los siguientes resultados:

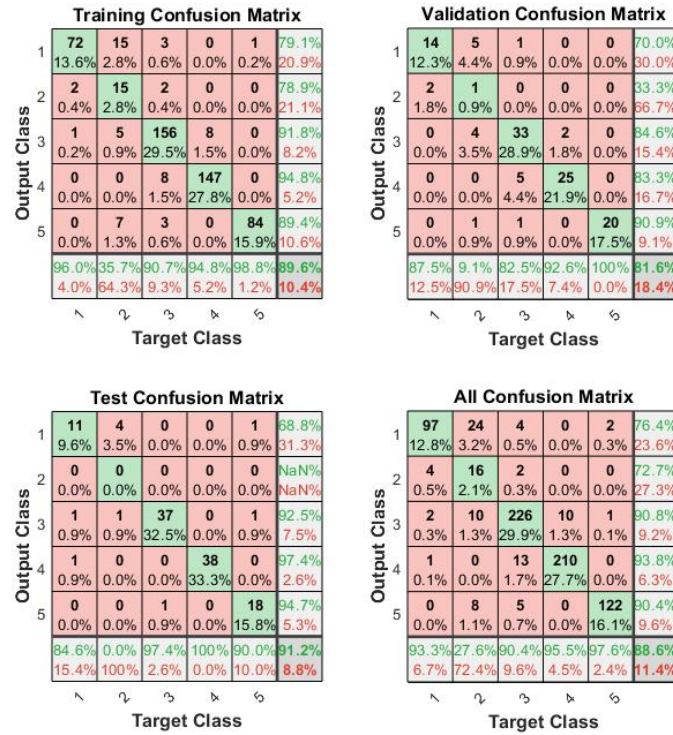


Figura 29: Matrices de confusión para la red neuronal.

Con la maquina de vectores de soporte se obtuvieron los siguientes resultados:

| | | | | | | | | |
|------------|---|----|----|-----|-----|-----|-----------------|------|
| True Class | 1 | 64 | 33 | 5 | 2 | | 8.5% | 5.3% |
| | 2 | 24 | 20 | 14 | | | 2.6% | 5.0% |
| | 3 | 9 | 8 | 221 | 12 | | 29.2% | 3.8% |
| | 4 | | 1 | 12 | 207 | | 27.3% | 1.7% |
| | 5 | | | | | 125 | 16.5% | |
| | | 1 | 2 | 3 | 4 | 5 | Predicted Class | |

Figura 30: Matrices de confusión para la maquina de vectores de soporte con kernel Lineal.

y al aplicar la validación cruzada se obtuvo un porcentaje de error de 15.8520 %

Con el clasificador k- nearest neighbor se obtuvieron los siguientes resultados:

| | | | | | | | | |
|------------|---|----|----|-----|-----|-----|-----------------|------|
| True Class | 1 | 99 | 1 | 1 | 3 | | 13.1% | 0.7% |
| | 2 | 21 | 17 | 13 | | 7 | 2.2% | 5.4% |
| | 3 | 3 | 1 | 229 | 8 | 9 | 30.3% | 2.8% |
| | 4 | 2 | | 19 | 198 | 1 | 26.2% | 2.9% |
| | 5 | 1 | | 3 | | 121 | 16.0% | 0.5% |
| | | 1 | 2 | 3 | 4 | 5 | Predicted Class | |

Figura 31: Matrices de confusión para k- nearest neighbor.

y al aplicar la validación cruzada se obtuvo un porcentaje de error de 12.2853 %

CAPÍTULO 11

Conclusiones

CAPÍTULO 12

Recomendaciones

- [1] J.Aguirre, «*Diseño, Análisis, y Desarrollo de un Sistema de Entrenamiento para Mejorar el Desempeño de los Atletas del Comité Olímpico Guatemalteco*», 2018.
- [2] M.Godoy, «*Sistema de Neurofeedback para mejorar el rendimiento de los Atletas del Comité Olímpico Guatemalteco. Diseño e implementación de módulo de recopilación de señales y módulo de retroalimentación*», 2018.
- [3] Aboalayon, K. A. I., Wafaa y Saeid, *Sleep Stage Classification Using EEG Signal Analysis: A Comprehensive Survey and New Investigation*, ago. de 2016. dirección: <https://www.mdpi.com/1099-4300/18/9/272>.
- [4] A. informationDisclosure statementNo potential conflict of interest was reported by the authors., *Sleep of professional athletes: Underexploited potential to improve health and performance*. dirección: <https://www.tandfonline.com/doi/full/10.1080/02640414.2016.1184300>.
- [5] *What are Brainwaves?* Dirección: <https://brainworksneurotherapy.com/what-are-brainwaves>.
- [6] C. A. Vinuesa Bonilla y col., “Sistema para monitoreo de ondas cerebrales en estudios de pulsos binaurales con ritmo theta sobre los procesos cognitivos y emocionales”, B.S. thesis, Quito: USFQ, 2016, 2016.
- [7] *How Do Binaural Beats Work?* Dirección: https://www.binauralbeatsmeditation.com/the-science/#The_Discovery_of_Binaural_Beats.
- [8] R. Villar-Documet, *Accueil*. dirección: <https://www.rvd-psychologue.com/es/neuroestimulacion-sonidos-binaurales.html>.
- [9] *Stages of Sleep - Non-REM and REM Sleep Cycles*. dirección: <https://www.tuck.com/stages/>.
- [10] N. M. Molina Culqui, “Sistema de monitoreo de las ondas cerebrales (electroencefalograma o EEG) presentes en el sueño: Análisis de frecuencia y coherencia del EEG en ambos hemisferios”, B.S. thesis, Quito, 2016., 2016.
- [11] E. Quirantes, *Medicina General*. dirección: <https://salud.ideal.es/general-61/2857-los-ciclos-del-sue%C3%B1o.html?ref=https://www.google.com/>.

- [12] *Home*. dirección: <https://electro-cap.com/index.cfm/caps/..>
- [13] F. G. N. E., *Manual de laboratorio de fisiología*. McGraw-Hill Interamericana, 2015.
- [14] *Third-Party Hardware · OpenBCI Documentation*. dirección: <https://docs.openbci.com/docs/05ThirdParty/ThirdPartyLanding>.
- [15] *Cyton Biosensing Board (8-channels)*. dirección: <https://shop.openbci.com/collections/frontpage/products/cyton-biosensing-board-8-channel?variant=38958638542>.
- [16] NetApp, *¿Qué es el aprendizaje automático (ML) y por qué es importante?*, ene. de 1970. dirección: <https://www.netapp.com/es/info/what-is-machine-learning-ml.aspx>.
- [17] F. S. Caparrini, *Redes Neuronales: una visión superficial*. dirección: <http://www.cs.us.es/~fsancho/?e=72>.
- [18] R. F. López y J. M. F. Fernández, *Las redes neuronales artificiales*. Netbiblo, 2008.
- [19] C. Saló Casajuana, *Clasificación de las fases del sueño utilizando señales EEG*, ene. de 2019.
- [20] *Mean absolute deviation (MAD) review (article)*. dirección: <https://www.khanacademy.org/math/statistics-probability/summarizing-quantitative-data/other-measures-of-spread/a/mean-absolute-deviation-mad-review>.
- [21] Dirección: <https://mindgeist.com/skills/pulsos-binaurales/>.

CAPÍTULO 14

Anexos

14.1. Planos de construcción

Curtosis La curtosis es una medida del grado de apuntamiento de una distribución en un conjunto de datos. Del mismo modo que el sesgo, la curtosis (k) describe la forma de la distribución de probabilidad.[19]. 40

Max Min Distance Se define como la distancia entre los puntos máximos y mínimo de un set de datos. 40

Mean Absolute Value La desviación absoluta media de un conjunto de datos es la distancia media entre cada punto de datos y la media. Nos da una idea sobre la variabilidad en un conjunto de datos.[20]. 40

Neurofeedback también llamado retroalimentación electroencefalografía, es un tratamiento neurocomportamental destinado a la adquisición de autocontrol sobre determinados patrones de actividad cerebral y la aplicación de estas habilidades en las actividades de la vida diaria.. 3

Pulsos binaurales Los pulsos binaurales son una ilusión auditiva percibida cuando dos ondas sinusoidales de tono puro se suman a otras produciendo una intermodulación que según algunos estudios ayudan a la sincronización de las ondas cerebrales[21]. 3

Slow wave activity Se define como la potencia en la banda delta (0.5-4 Hz) de la señal EEG y se considera como el mejor indicador de la intensidad de sueño profundo[19]. 40

Zero Crossing Un cruce por cero es un punto donde cambia el signo de una función matemática, representado por una intersección del eje en el gráfico de la función. Es un término comúnmente usado en electrónica, matemáticas, acústica y procesamiento de imágenes.. 40